



MÉTHODES QUANTITATIVES 1 • CHAPITRE 1

Présentation des données

Corrigés détaillés

Badr ABOUFARASSE, PhD.

KEDGE Business School

1. Vocabulaire statistique

Une enquête interroge 240 étudiants de première année sur leur programme, leur mode de transport, leur satisfaction (de 1 à 5), leur nombre d'absences et leur temps de trajet en minutes.

- 1 Identifiez la population, l'unité statistique et les cinq variables.
- 2 Classez chaque variable comme nominale, ordinale, discrète ou continue.
- 3 Donnez une valeur possible pour chaque variable.

Aide méthodologique. Classez une variable d'après la signification de ses valeurs, et non d'après la manière dont elle est codée.

Corrigé détaillé

Méthode. La population est l'ensemble sur lequel porte la question de recherche ; l'unité statistique est une entité sur laquelle les observations sont enregistrées.

Résultat. La population correspond aux 240 étudiants interrogés si l'objectif est de décrire ces répondants. L'unité est un étudiant. Le programme et le mode de transport sont des variables qualitatives nominales. La satisfaction est qualitative ordinale : les modalités sont classées, mais les écarts ne sont pas nécessairement égaux. Le nombre d'absences est quantitatif discret puisqu'il est dénombré. Le temps de trajet est quantitatif continu.

Interprétation. Un code numérique ne transforme pas automatiquement une variable en variable quantitative : une satisfaction codée de 1 à 5 reste ordinale.

2. Population, échantillon et biais

KEDGE souhaite connaître le temps de trajet moyen de ses 1 200 étudiants de première année. Un questionnaire en ligne est publié à 8 h ; 180 volontaires répondent avant midi.

- 1 Définissez la population cible et l'échantillon.
- 2 L'échantillon est-il nécessairement représentatif ? Identifiez deux biais plausibles.
- 3 Proposez un meilleur plan d'échantillonnage.

Aide méthodologique. Distinguez le groupe sur lequel on souhaite conclure du groupe effectivement observé. La taille ne garantit pas la représentativité.

Corrigé détaillé

Méthode. Il faut distinguer la population cible du groupe effectivement observé. La représentativité dépend du mécanisme de sélection et pas uniquement de la taille de l'échantillon.

Résultat. La population cible comprend les 1 200 étudiants de première année ; l'échantillon contient les 180 volontaires. Le volontariat peut surreprésenter les étudiants les plus engagés. La fenêtre matinale peut sous-représenter ceux qui sont en trajet ou en cours. Une meilleure méthode consiste à tirer aléatoirement des étudiants dans la liste complète, éventuellement en stratifiant par programme ou campus, puis à effectuer des relances et une analyse de la non-réponse.

Interprétation. Un échantillon de 180 personnes peut rester biaisé. La sélection aléatoire et la couverture sont plus importantes que le seul nombre de réponses.

3. Construire une distribution de fréquences

Les nombres d'achats effectués par 20 clients sont : 0, 1, 2, 1, 3, 2, 2, 4, 1, 0, 2, 3, 1, 2, 5, 3, 2, 1, 4, 2.

- 1 Construisez les effectifs, les fréquences relatives, les effectifs cumulés et les fréquences cumulées.
- 2 Déterminez la proportion de clients ayant effectué au plus deux achats.
- 3 Choisissez une représentation graphique appropriée et justifiez votre choix.

Aide méthodologique. Commencez par ordonner les valeurs distinctes de 0 à 5. La fréquence relative est égale à l'effectif divisé par 20.

Corrigé détaillé

Méthode. On ordonne les valeurs, on compte chaque occurrence, on divise chaque effectif par $n = 20$, puis on cumule à partir de la plus petite valeur.

x	0	1	2	3	4	5
Effectif	2	5	7	3	2	1
Fréquence	0,10	0,25	0,35	0,15	0,10	0,05
Effectif cumulé	2	7	14	17	19	20
Fréquence cumulée	0,10	0,35	0,70	0,85	0,95	1,00

Résultat. La proportion ayant réalisé au plus deux achats est $14/20 = 70\%$. Un diagramme en bâtons convient puisque la variable est discrète.

Interprétation. Sept clients, soit 35% , ont effectué exactement deux achats, tandis que 70% en ont effectué deux ou moins.

4. Classes inégales et graphiques responsables

Les temps de livraison sont regroupés ainsi : $[0,5[: 20$; $[5,10[: 30$; $[10,20[: 40$; $[20,40[: 20$.

- 1 Calculez les amplitudes, les fréquences relatives et les densités d'effectifs.
- 2 Expliquez pourquoi représenter les effectifs comme hauteurs serait trompeur.
- 3 Identifiez la classe modale à partir des densités.

Aide méthodologique. Avec des classes d'amplitudes différentes, c'est l'aire de chaque rectangle qui doit représenter la fréquence. Densité = effectif $\div$ amplitude.

Corrigé détaillé

Méthode. Avec des intervalles inégaux, l'aire de l'histogramme, et non sa hauteur, doit représenter la fréquence. La densité d'effectif est égale à l'effectif divisé par l'amplitude.

Classe	$[0,5[$	$[5,10[$	$[10,20[$	$[20,40[$
Amplitude	5	5	10	20
Effectif	20	30	40	20
Fréquence relative	0,182	0,273	0,364	0,182
Densité	4	6	4	1

Résultat. La classe modale selon la densité est $[5,10[$. Utiliser les effectifs comme hauteurs exagérerait les classes larges et produirait des aires sans rapport avec les fréquences.

Interprétation. Un histogramme correct conserve la fréquence par l'aire des rectangles et permet une comparaison équitable entre classes d'amplitudes différentes.

5. Audit d'un tableau de bord

Un responsable affirme que la satisfaction a « doublé » parce qu'un graphique à axe tronqué passe de 3,8 à 4,2. Il affirme aussi que l'échantillon représente l'école alors que seuls les membres d'une association étudiante ont répondu. Relevez quatre problèmes statistiques, proposez une communication corrigée et formulez une conclusion défendable.

Aide méthodologique. Examinez le calcul de variation, l'échelle du graphique, le cadre d'échantillonnage et le domaine auquel la conclusion peut être généralisée.

Corrigé détaillé

Méthode. Il faut auditer le cadre d'échantillonnage, l'échelle graphique, l'affirmation numérique et le domaine d'inférence.

Résultat. Premièrement, 4,2 n'est pas le double de 3,8 : la hausse est de $(4,2/3,8 - 1) \times 100 = 10,53 \%$. Deuxièmement, l'axe tronqué amplifie visuellement la variation. Troisièmement, les membres de l'association constituent un échantillon de convenance. Quatrièmement, la moyenne d'une variable ordinale devrait être accompagnée de la distribution complète. Il faut utiliser une échelle clairement indiquée de 1 à 5, montrer les pourcentages par modalité, préciser la taille et le recrutement de l'échantillon, et éviter toute généralisation abusive.

Interprétation. Conclusion défendable : « Parmi les membres de l'association ayant répondu, la satisfaction moyenne déclarée est passée de 3,8 à 4,2. Cette hausse de 0,4 point ne peut pas être automatiquement généralisée à l'ensemble des étudiants. »

6. Choisir la représentation appropriée

Pour chaque variable, choisissez un graphique pertinent et justifiez : programme d'études ; satisfaction de 1 à 5 ; revenu mensuel ; ventes quotidiennes pendant 30 jours ; parts de marché de quatre marques.

Aide méthodologique. Reliez le graphique au type de variable et à la question analytique.

Corrigé détaillé

Programme : diagramme en barres. Satisfaction : barres ordonnées. Revenu : histogramme ou boîte à moustaches. Ventes quotidiennes : courbe chronologique. Parts de marché : barres pour comparer précisément ; un secteur n'est acceptable que si les quatre parts forment un total.

Idée essentielle. Un graphique répond à une question ; il ne sert pas seulement à décorer.

7. Tableau croisé et pourcentages conditionnels

Parmi 120 étudiants, 50 utilisent les transports publics, dont 30 femmes. Parmi les 70 autres étudiants, 35 sont des femmes.

- 1 Construisez le tableau sexe × transport.
- 2 Calculez le taux d'utilisation des transports publics dans chaque groupe.
- 3 Indiquez si une association semble présente.

Aide méthodologique. Un pourcentage conditionnel utilise comme dénominateur le total du groupe conditionnant.

Corrigé détaillé

Tableau : femmes 30 « public » et 35 « autre » ; hommes 20 et 35. Totaux : 65 femmes et 55 hommes. Les taux conditionnels sont $30/65 = 46,2 \%$ et $20/55 = 36,4 \%$.

L'écart observé vaut 9,8 points. Il décrit une association dans l'échantillon, sans démontrer une différence dans la population ni un effet causal.

8. Protocole de qualité et de communication

Un export CRM contient des clients dupliqués, des âges manquants codés 999, des dates incohérentes et des revenus saisis en euros ou en milliers d'euros. Proposez un protocole reproductible en six étapes avant de produire un tableau de bord.

Aide méthodologique. Séparez validation, nettoyage, documentation et communication.

Corrigé détaillé

- 1 Conserver un fichier brut immuable et les identifiants.
- 2 Établir un dictionnaire des variables et unités.
- 3 Détecter les doublons et définir une règle de conservation.
- 4 Recoder 999 en valeur manquante et analyser la non-réponse.
- 5 Contrôler dates, plages et cohérence logique.
- 6 Uniformiser les unités monétaires, documenter les transformations et publier les contrôles.

On ne remplace jamais silencieusement les valeurs manquantes et on ne supprime pas automatiquement les observations inhabituelles.

9. Cas de préparation au contrôle : consentement à payer

Étude de cas — 12 points. Une enseigne alimentaire interroge 200 clients sur le prix maximal qu'ils accepteraient de payer pour une boîte-repas durable.

Prix maximal (€)	[20,25[	[25,30[	[30,40[	[40,50[	[50,60[	[60,80[
Clients	10	20	50	60	40	20

- 1 Identifiez la population, l'unité statistique, la variable et sa nature. (2 points)
- 2 Calculez les amplitudes, les fréquences relatives et les densités. (3 points)
- 3 Expliquez la construction de l'histogramme correct et identifiez la classe modale. (2 points)
- 4 Calculez les effectifs cumulés croissants et décroissants. Donnez les coordonnées nécessaires aux deux courbes cumulées. (3 points)
- 5 Déterminez le prix maximal qu'au moins 60 % des clients interrogés accepteraient de payer. Expliquez le percentile utilisé. (2 points)

Aide méthodologique. Avec des classes d'amplitudes différentes, utilisez les densités. Pour la décision de prix, traduisez « au moins 60 % peuvent payer » en pourcentage cumulé croissant.

Corrigé détaillé et logique du barème

1. Population : les 200 clients interrogés ; unité : un client interrogé ; variable : consentement maximal à payer en euros ; nature : quantitative continue.

Classe	Amplitude	Effectif	Fréquence	Densité	ECC
[20,25[	5	10	5 %	2	10
[25,30[	5	20	10 %	4	30
[30,40[	10	50	25 %	5	80
[40,50[	10	60	30 %	6	140
[50,60[	10	40	20 %	4	180
[60,80[	20	20	10 %	1	200

2-3. Les amplitudes étant différentes, les hauteurs de l'histogramme sont les densités et non les effectifs bruts. La densité maximale vaut 6 : la classe modale est

[40,50[.

4. La courbe croissante passe par (20,0), (25,10), (30,30), (40,80), (50,140), (60,180), (80,200). La courbe décroissante utilise (20,200), (25,190), (30,170), (40,120), (50,60), (60,20), (80,0).

5. Si au moins 60 % doivent pouvoir payer, au plus 40 % peuvent avoir un consentement inférieur au prix choisi. Quarante pour cent de 200 représentent 80 clients, seuil atteint à 40 €. On utilise donc le 40e percentile, et non le 60e : le prix maximal recommandé est 40 €.

Réflexe d'évaluation. Énoncez la règle, présentez le calcul, puis interprétez le résultat dans le contexte de la décision.

10. Synthèse type examen : présenter la satisfaction client

Cas autonome — 10 points. Deux magasins recueillent la satisfaction sur une échelle ordonnée de 1 (très insatisfait) à 5 (très satisfait).

Note	1	2	3	4	5	Total
Magasin A	6	10	18	36	30	100
Magasin B	4	12	30	34	20	100

- 1 Identifiez la variable et son échelle de mesure. (1 point)
- 2 Choisissez et justifiez un graphique permettant de comparer les deux magasins. Décrivez précisément sa construction. (2 points)
- 3 Calculez, pour chaque magasin, la proportion de notes 4 ou 5 et le pourcentage cumulé de notes inférieures ou égales à 2. (3 points)
- 4 Un responsable affirme : « Le magasin A est 50 % meilleur, car il obtient 30 notes de 5 contre 20. » Critiquez cette affirmation. (2 points)
- 5 Rédigez une conclusion statistique en trois phrases incluant une limite de l'enquête. (2 points)

Aide méthodologique. Conservez l'ordre des modalités, comparez les pourcentages et distinguez description et causalité.

Corrigé détaillé

1. La satisfaction est qualitative ordinaire : les modalités sont ordonnées, mais les écarts entre deux notes successives ne sont pas nécessairement égaux.
2. Utiliser des barres groupées ou des barres empilées à 100 %, en conservant l'ordre 1-5, avec les mêmes axes et les pourcentages. Un histogramme ne convient pas : les modalités sont ordinales et non des intervalles continus.
3. Magasin A : notes 4-5 = $(36+30)/100 = 66\%$; notes au plus égales à 2 = $(6+10)/100 = 16\%$. Magasin B : notes 4-5 = $(34+20)/100 = 54\%$; notes au plus égales à 2 = $(4+12)/100 = 16\%$.
4. Trente est bien supérieur de 50 % à vingt, mais ce calcul isole une seule modalité et ne signifie pas que le magasin est « 50 % meilleur ». Pour les notes 4-5, l'écart est de 12 points ; la méthode d'échantillonnage et l'incertitude sont inconnues, et aucune causalité n'est établie.

5. Conclusion modèle. « Dans les échantillons interrogés, le magasin A présente davantage de notes favorables (66 %) que le magasin B (54 %), tandis que les deux magasins comptent 16 % de notes 1 ou 2. Cette différence reste descriptive et ne prouve pas à elle seule que le magasin A offre un meilleur service. Avant toute généralisation, il faut connaître la sélection des clients, les taux de réponse et la comparabilité des périodes. »