Fiche 1

Présenter et organiser les données

Corrigés détaillés

Badr ABOUFARASSE, PhD

1. Applications fondamentales

Maîtriser les définitions et les calculs essentiels du cours.

Application du cours 10 min

Exercice 1 – Population, échantillon et nature des variables

Un magasin souhaite étudier l'ensemble de ses clients ayant effectué un achat au mois de septembre. Il interroge un échantillon de 80 clients et relève :

Variable	Exemple
Mode de paiement	carte, espèces, mobile
Nombre d'articles achetés	1, 2, 3, …
Temps passé en magasin	en minutes
Niveau de satisfaction	très insatisfait à très satisfait

1. Identifier la population cible, l'échantillon et l'unité statistique.
2. Classer chaque variable comme qualitative nominale, qualitative ordinale, quantitative discrète ou quantitative continue.
3. Choisir une représentation graphique adaptée à chaque variable.
4. Pour quelles variables les fréquences cumulées ont-elles un sens ? Justifier.
5. Expliquer pourquoi un échantillon de grande taille n'est pas nécessairement représentatif.

Exercice 1 – Corrigé

Population cible : tous les clients ayant effectué un achat en septembre. Échantillon : les 80 clients interrogés. Unité statistique : un client.

Variable	Nature	Graphique adapté
Mode de paiement	qualitative nominale	diagramme en barres / secteurs
Nombre d’articles	quantitative discrète	diagramme en bâtons
Temps en magasin	quantitative continue	histogramme
Satisfaction	qualitative ordinale	barres ordonnées

Les fréquences cumulées ont un sens pour les variables possédant un ordre : nombre d’articles, temps, satisfaction. Elles n’ont pas de sens pour le mode de paiement, car les modalités nominales ne possèdent pas d’ordre naturel.

Un grand échantillon peut rester biaisé si la sélection n’est pas représentative. Par exemple, une enquête volontaire peut attirer davantage les clients très satisfaits ou très engagés.

Application du cours 20 min

Exercice 2 – Distribution discrète

Le nombre de commandes passées par 40 clients est résumé par :

x_i	0	1	2	3	4	5
n_i	3	7	12	10	6	2

1. Vérifier l’effectif total N.
2. Calculer les fréquences $f_i = n_i/N$ et les fréquences cumulées croissantes.
3. Représenter la distribution par un diagramme en bâtons.
4. Construire la fonction de répartition $F(x) = P(X \le x)$.
5. Déterminer la proportion de clients ayant passé au plus trois commandes.

Exercice 2 – Corrigé détaillé

$$N = 3 + 7 + 12 + 10 + 6 + 2 = 40.$$

x_i	0	1	2	3	4	5
n_i	3	7	12	10	6	2
f_i	0.075	0.175	0.300	0.250	0.150	0.050
F_i	0.075	0.250	0.550	0.800	0.950	1.000

Exemple de calcul :

$$f_2 = \frac{12}{40} = 0.30 = 30\%.$$

La proportion ayant passé au plus trois commandes vaut :

$$F(3) = \frac{3 + 7 + 12 + 10}{40} = \frac{32}{40} = 0.80 = 80\%.$$

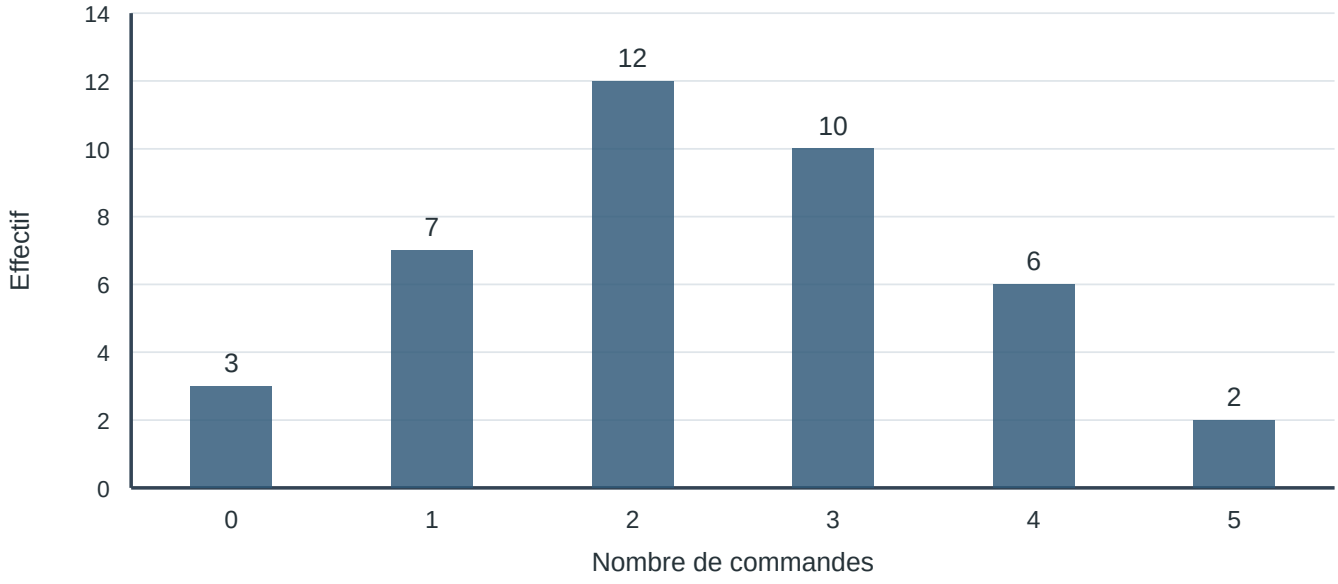
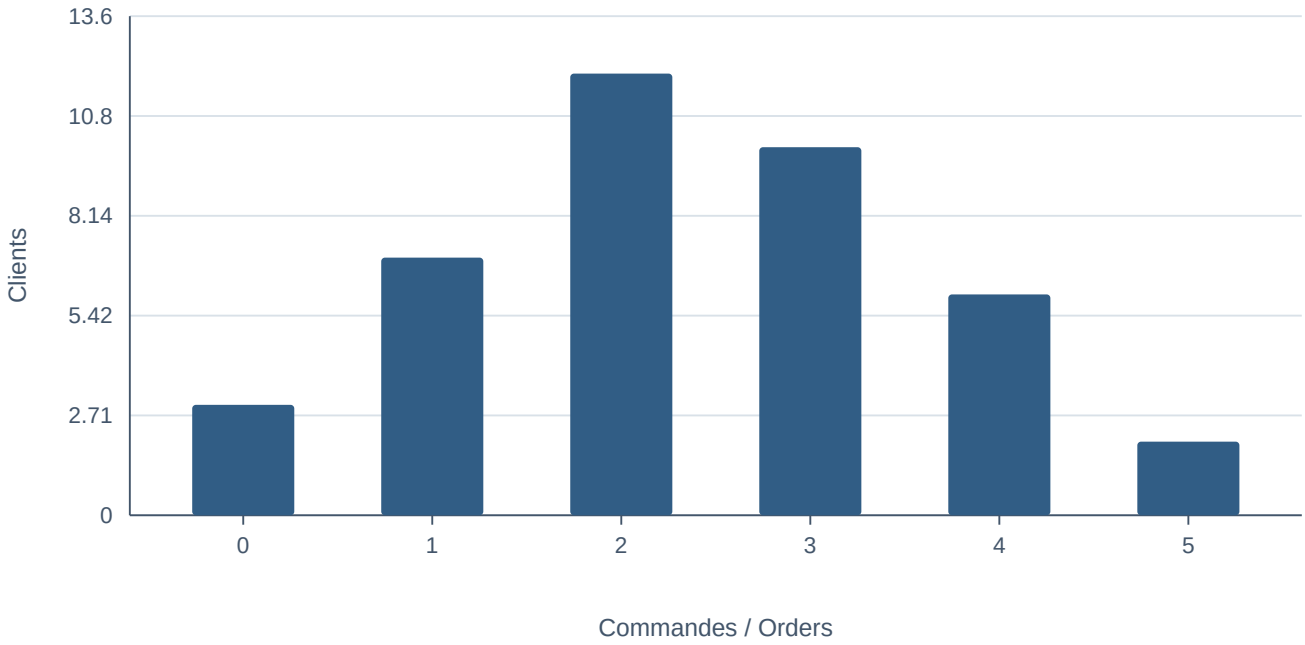
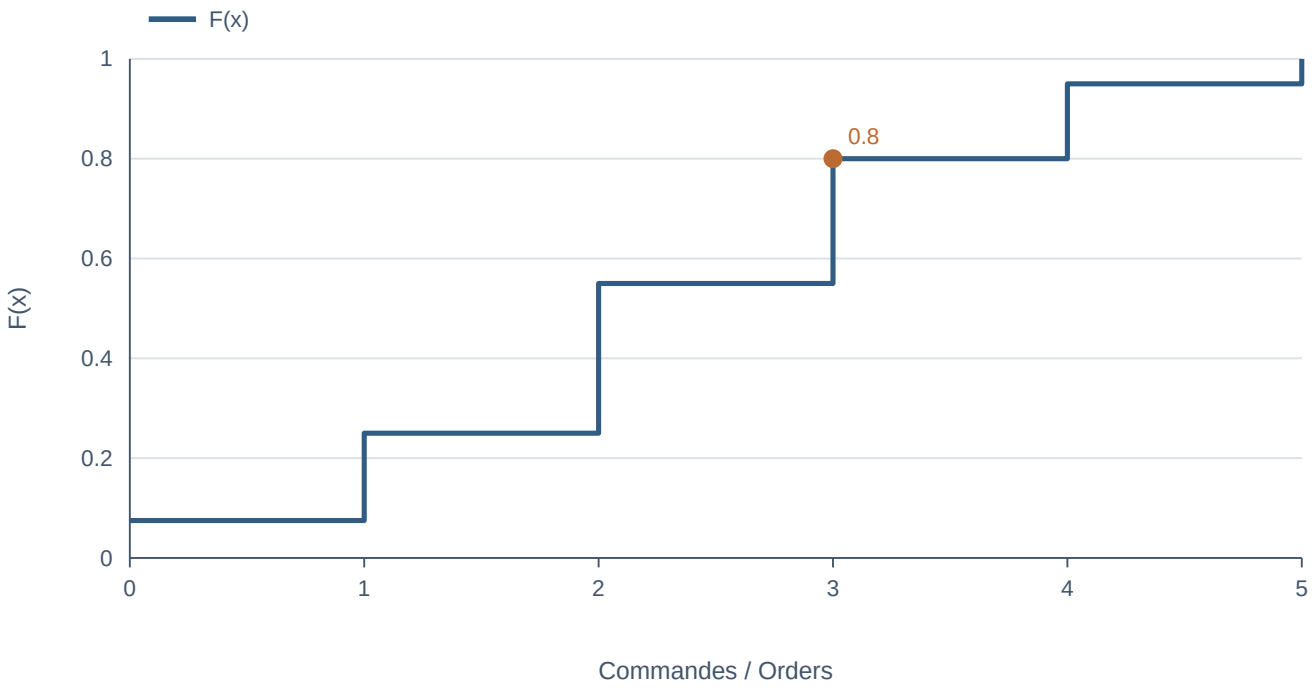


Diagramme en bâtons : nombre de commandes

Graphiques construits à partir des effectifs : la fonction de répartition atteint 80 % à x=3.



Nombre de commandes / Orders



Fonction de répartition / Empirical CDF

Tableau exhaustif des cumuls

x	n	f=n/40	ECC	ECD	FCC	FCD
0	3	3/40=.075	3	40	.075	1.000
1	7	7/40=.175	10	37	.250	.925
2	12	12/40=.300	22	30	.550	.750
3	10	10/40=.250	32	18	.800	.450
4	6	6/40=.150	38	8	.950	.200
5	2	2/40=.050	40	2	1.000	.050

À x=3, ECC=3+7+12+10=32 et ECD=10+6+2=18. Les fréquences cumulées croissantes mesurent $P(X \leq x)$, les décroissantes $P(X \geq x)$.

Application du cours 15 min

Complément 1 — Tableau croisé et pourcentages conditionnels

Parmi 120 étudiants, 50 utilisent les transports publics, dont 30 femmes. Parmi les 70 autres étudiants, 35 sont des femmes.

1. Construisez le tableau sexe × transport.
2. Calculez le taux d’utilisation des transports publics dans chaque groupe.
3. Indiquez si une association semble présente.

Un pourcentage conditionnel utilise comme dénominateur le total du groupe conditionnant.

Complément 1 — Tableau croisé et pourcentages conditionnels

Corrigé détaillé

Tableau : femmes 30 « public » et 35 « autre » ; hommes 20 et 35. Totaux : 65 femmes et 55 hommes. Les taux conditionnels sont 30/65 = 46,2 % et 20/55 = 36,4 %.

L'écart observé vaut 9,8 points. Il décrit une association dans l'échantillon, sans démontrer une différence dans la population ni un effet causal.

2. Préparation aux évaluations

Résoudre des exercices de contrôle continu et de partiel en autonomie.

Préparation CC / partiel 40 min

Exercice 3 – Variable continue et classes d'amplitudes inégales

On observe le prix maximal, en euros, que 210 clients sont prêts à payer :

Classe	$[10,14[$	$[14,18[$	$[18,26[$	$[26,30[$	$[30,35[$	$[35,40[$	$[40,45[$	$[45,50[$	$[50,55[$
n_i	4	12	32	32	60	35	25	5	5

1. Calculer, pour chaque classe, l'amplitude a_i, la fréquence f_i et la densité d'effectif $d_i = n_i/a_i$.
2. Construire l'histogramme correct et expliquer pourquoi la hauteur ne peut pas être directement l'effectif lorsque les amplitudes sont différentes.
3. Calculer les effectifs cumulés croissants (ECC) et décroissants (ECD), ainsi que les fréquences cumulées correspondantes.
4. Tracer les courbes cumulatives.
5. Déterminer le nombre et la proportion de clients prêts à payer moins de 35 euros, puis au moins 35 euros.

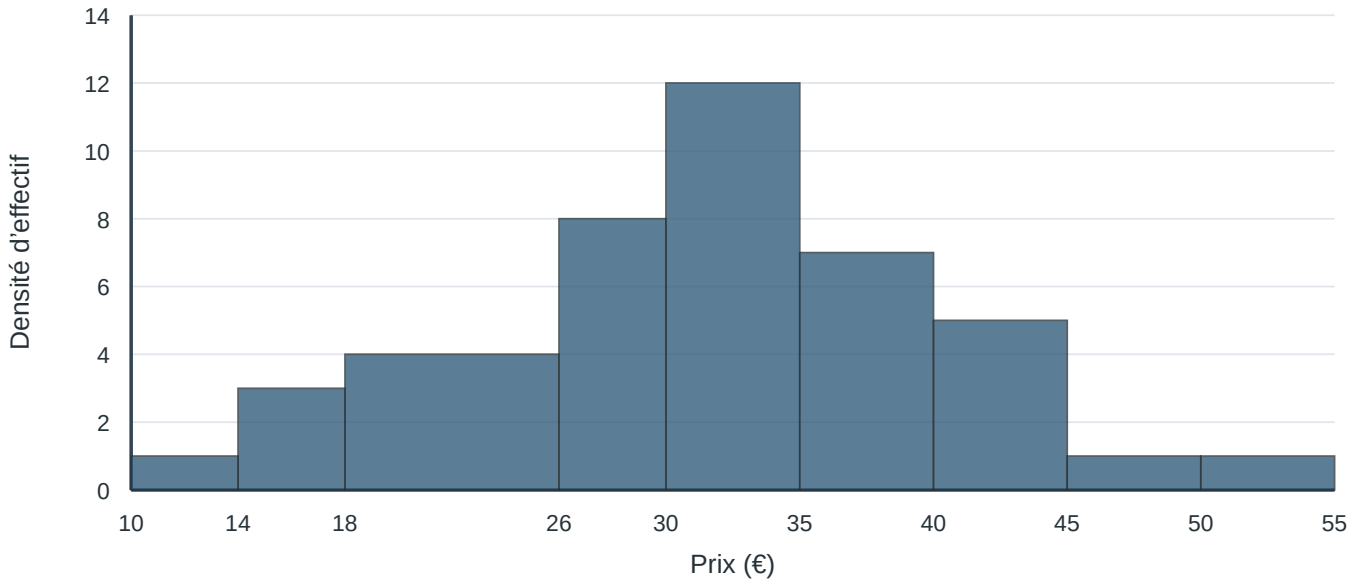
Exercice 3 – Corrigé détaillé

Classe	$[10,14[$	$[14,18[$	$[18,26[$	$[26,30[$	$[30,35[$	$[35,40[$	$[40,45[$	$[45,50[$	$[50,55[$
n_i	4	12	32	32	60	35	25	5	5
a_i	4	4	8	4	5	5	5	5	5
$f_i(\%)$	1.90	5.71	15.24	15.24	28.57	16.67	11.90	2.38	2.38
d_i	1	3	4	8	12	7	5	1	1
ECC	4	16	48	80	140	175	200	205	210
ECD	210	206	194	162	130	70	35	10	5

Par exemple :

$$f_{[18,26[} = \frac{32}{210} \approx 0.1524 = 15.24\%, \qquad d_{[18,26[} = \frac{32}{8} = 4.$$

Lorsque les largeurs de classes diffèrent, c’est l’aire du rectangle qui doit représenter l’effectif. On utilise donc la densité comme hauteur.



Histogramme à classes d’amplitudes inégales

Sous 35 euros :

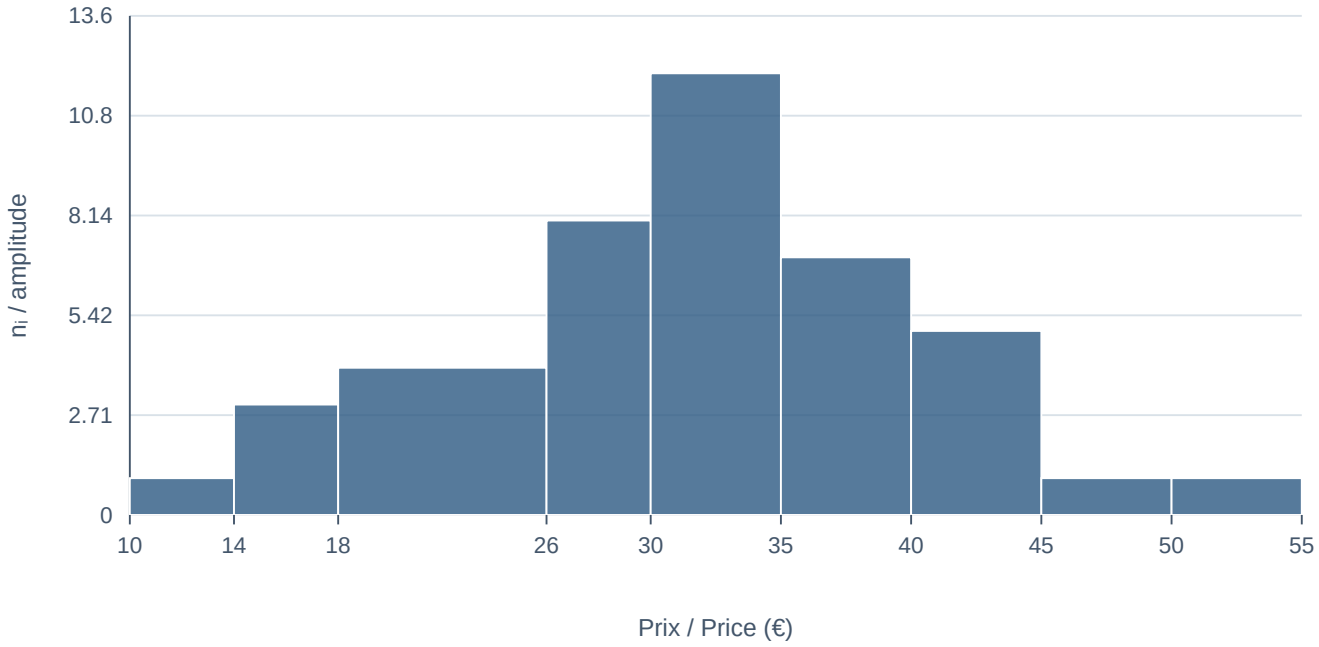
$$4 + 12 + 32 + 32 + 60 = 140, \qquad \frac{140}{210} = 66.67\%.$$

Au moins 35 euros :

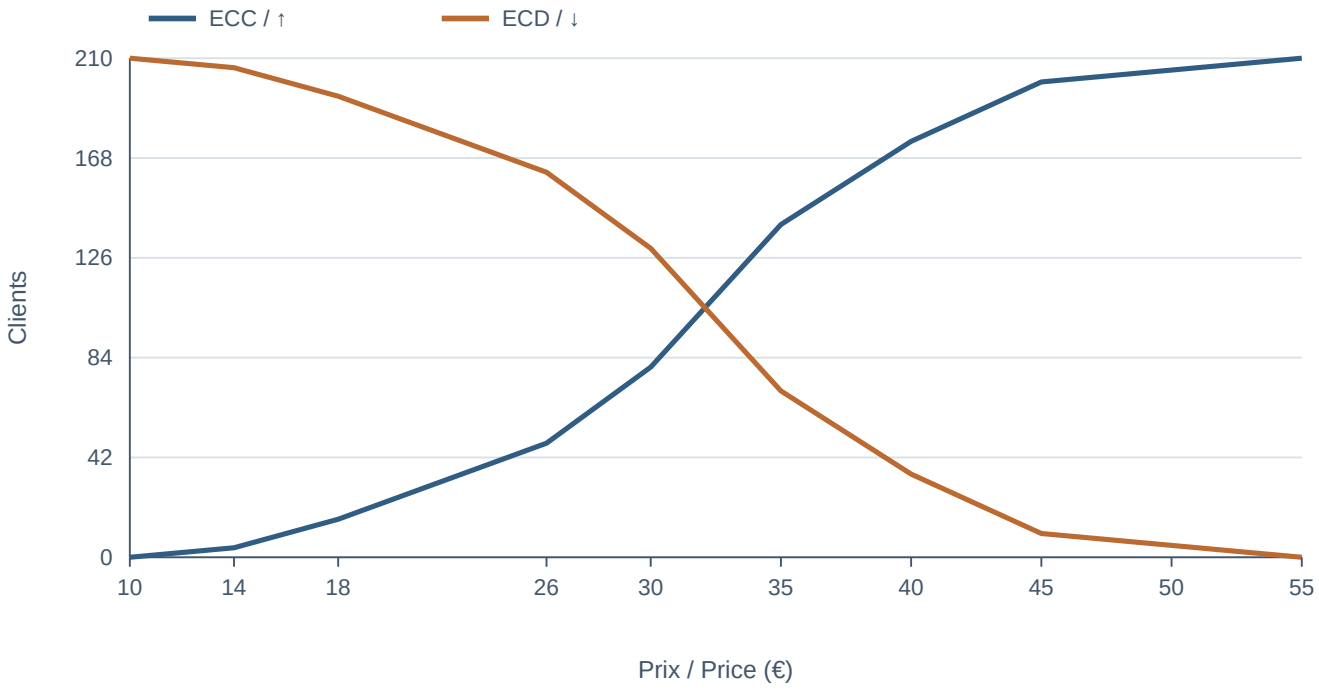
$$35 + 25 + 5 + 5 = 70, \qquad \frac{70}{210} = 33.33\%.$$

Tableau exhaustif : $f_i = n_i/210$; FCC=ECC/210 ; FCD=ECD/210. Les courbes cumulées utilisent les bornes des classes.

Classe	a_i	n_i	f_i (%)	d_i	ECC	ECD	FCC (%)	FCD (%)
[10,14[	4	4	1.90	1	4	210	1.90	100.00
[14,18[	4	12	5.71	3	16	206	7.62	98.10
[18,26[	8	32	15.24	4	48	194	22.86	92.38
[26,30[	4	32	15.24	8	80	162	38.10	77.14
[30,35[	5	60	28.57	12	140	130	66.67	61.90
[35,40[	5	35	16.67	7	175	70	83.33	33.33
[40,45[	5	25	11.90	5	200	35	95.24	16.67
[45,50[	5	5	2.38	1	205	10	97.62	4.76
[50,55[	5	5	2.38	1	210	5	100.00	2.38
TOTAL	—	210	100	—	210	—	100	—



Histogramme des densités / Density histogram



Effectifs cumulés / Cumulative counts

Préparation CC / partiel 35 min

Complément 3 — Cas de préparation au contrôle : consentement à payer

Étude de cas — 12 points. Une enseigne alimentaire interroge 200 clients sur le prix maximal qu'ils accepteraient de payer pour une boîte-repas durable.

Prix maximal (€)	**[20,25[**	**[25,30[**	**[30,40[**	**[40,50[**	**[50,60[**	**[60,80[**
Clients	10	20	50	60	40	20

1. Identifiez la population, l'unité statistique, la variable et sa nature. *(2 points)*
2. Calculez les amplitudes, les fréquences relatives et les densités. *(3 points)*
3. Expliquez la construction de l'histogramme correct et identifiez la classe modale. *(2 points)*
4. Calculez les effectifs cumulés croissants et décroissants. Donnez les coordonnées nécessaires aux deux courbes cumulées. *(3 points)*
5. Déterminez le prix maximal qu'au moins 60 % des clients interrogés accepteraient de payer. Expliquez le percentile utilisé. *(2 points)*

Avec des classes d'amplitudes différentes, utilisez les densités. Pour la décision de prix, traduisez « au moins 60 % peuvent payer » en pourcentage cumulé croissant.

Complément 3 — Cas de préparation au contrôle : consentement à payer

Corrigé détaillé et logique du barème

1. Population : les 200 clients interrogés ; unité : un client interrogé ; variable : consentement maximal à payer en euros ; nature : quantitative continue.

Classe	Amplitude	Effectif	Fréquence	Densité	ECC
[20,25[	5	10	5 %	2	10
[25,30[	5	20	10 %	4	30
[30,40[	10	50	25 %	5	80
[40,50[	10	60	30 %	6	140
[50,60[	10	40	20 %	4	180
[60,80[	20	20	10 %	1	200

2–3. Les amplitudes étant différentes, les hauteurs de l'histogramme sont les densités et non les effectifs bruts. La densité maximale vaut 6 : la classe modale est [40,50[.

4. La courbe croissante passe par (20,0), (25,10), (30,30), (40,80), (50,140), (60,180), (80,200). La courbe décroissante utilise (20,200), (25,190), (30,170), (40,120), (50,60), (60,20), (80,0).

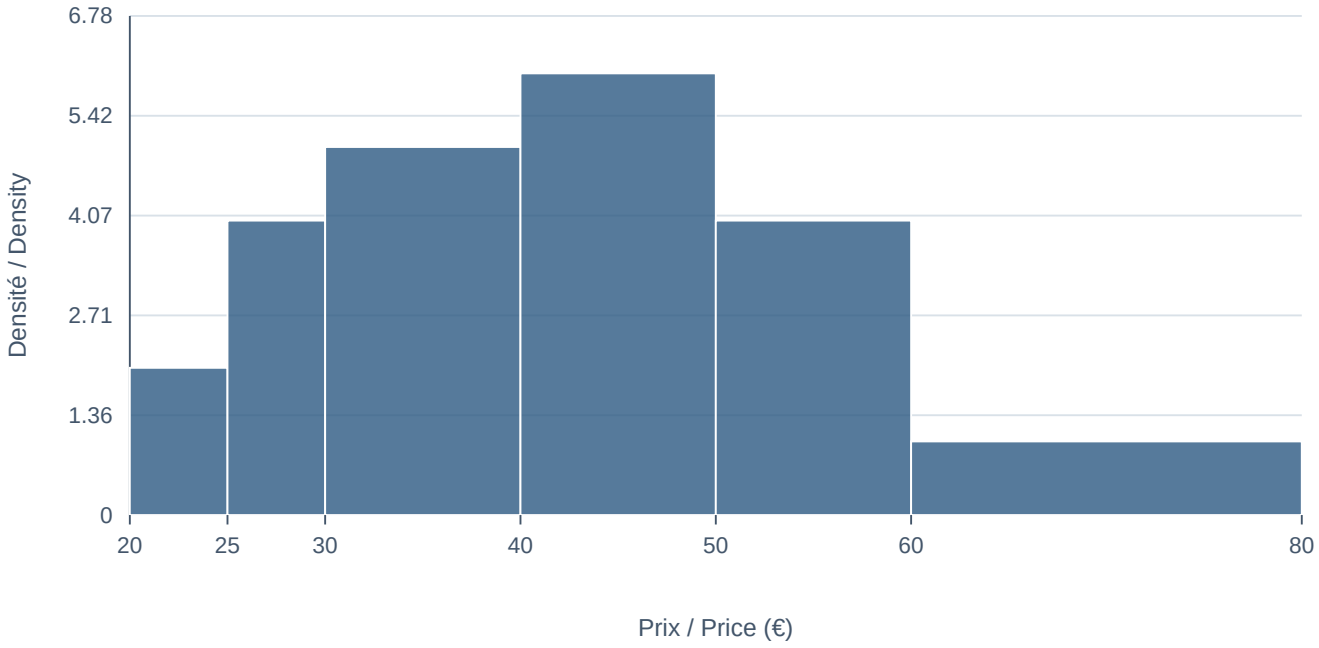
5. Si au moins 60 % doivent pouvoir payer, au plus 40 % peuvent avoir un consentement inférieur au prix choisi. Quarante pour cent de 200 représentent 80 clients, seuil atteint à 40 €. On utilise donc le 40e percentile, et non le 60e : le prix maximal recommandé est **40 €**.

Réflexe d'évaluation. Énoncez la règle, présentez le calcul, puis interprétez le résultat dans le contexte de la décision.

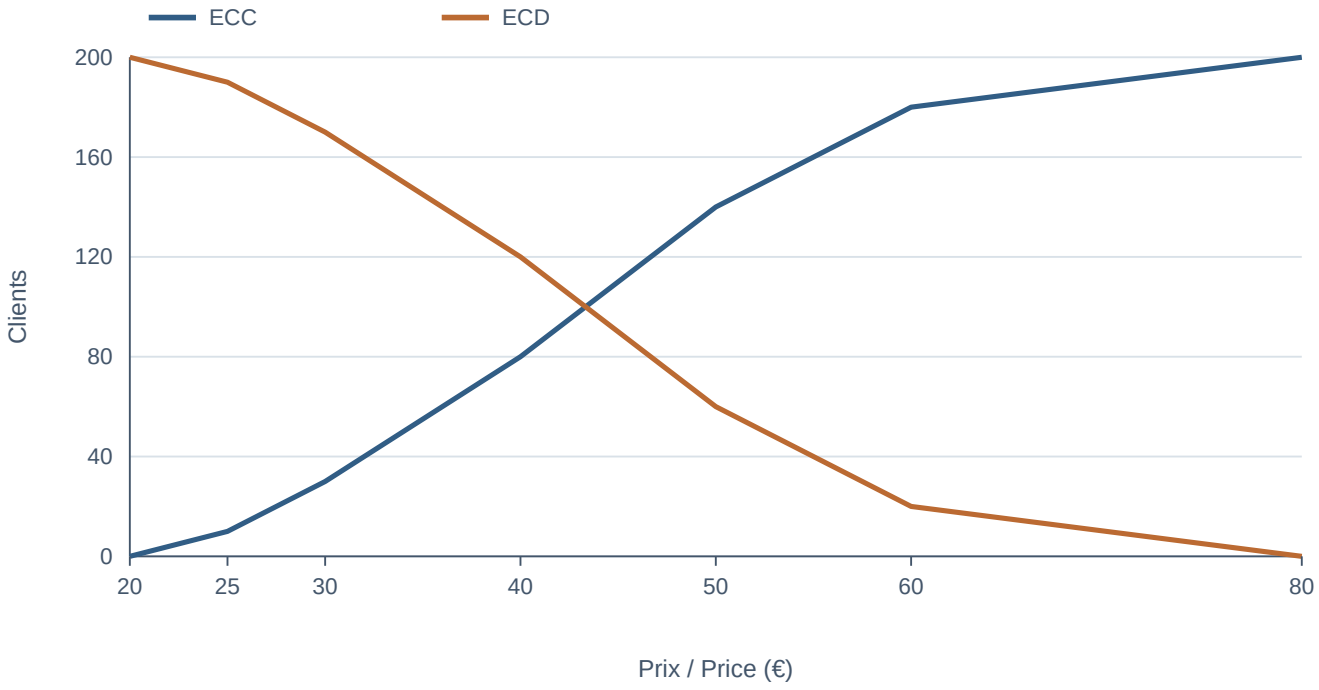
Tableau intégral et représentations graphiques (hauteurs de l'histogramme = effectifs/amplitudes) :

Classe / Class	n_i	a_i	f_i (%)	d_i	ECC	ECD	FCC (%)	FCD (%)
[20,25[	10	5	5.00	2	10	200	5.00	100.00
[25,30[	20	5	10.00	4	30	190	15.00	95.00
[30,40[	50	10	25.00	5	80	170	40.00	85.00
[40,50[	60	10	30.00	6	140	120	70.00	60.00

Classe / Class	n_i	a_i	f_i (%)	d_i	ECC	ECD	FCC (%)	FCD (%)
[50,60[	40	10	20.00	4	180	60	90.00	30.00
[60,80[	20	20	10.00	1	200	20	100.00	10.00



Consentement à payer / Willingness-to-pay histogram



Courbes cumulatives / Cumulative counts

Le seuil de 40 € est le 40e percentile : 80 clients sur 200 acceptent moins de 40 €, donc environ 60 % peuvent payer au moins 40 €.

Préparation CC / partiel 30 min

Complément 4 — Synthèse type examen : présenter la satisfaction client

Cas autonome — 10 points. Deux magasins recueillent la satisfaction sur une échelle ordonnée de 1 (très insatisfait) à 5 (très satisfait).

Note	1	2	3	4	5	Total
Magasin A	6	10	18	36	30	100
Magasin B	4	12	30	34	20	100

1. Identifiez la variable et son échelle de mesure. *(1 point)*
2. Choisissez et justifiez un graphique permettant de comparer les deux magasins. Décrivez précisément sa construction. *(2 points)*
3. Calculez, pour chaque magasin, la proportion de notes 4 ou 5 et le pourcentage cumulé de notes inférieures ou égales à 2. *(3 points)*
4. Un responsable affirme : « Le magasin A est 50 % meilleur, car il obtient 30 notes de 5 contre 20. » Critiquez cette affirmation. *(2 points)*
5. Rédigez une conclusion statistique en trois phrases incluant une limite de l'enquête. *(2 points)*

Conservez l'ordre des modalités, comparez les pourcentages et distinguez description et causalité.

Complément 4 — Synthèse type examen : présenter la satisfaction client

Corrigé détaillé

1. La satisfaction est qualitative ordinale : les modalités sont ordonnées, mais les écarts entre deux notes successives ne sont pas nécessairement égaux.

2. Utiliser des barres groupées ou des barres empilées à 100 %, en conservant l'ordre 1–5, avec les mêmes axes et les pourcentages. Un histogramme ne convient pas : les modalités sont ordinales et non des intervalles continus.

3. Magasin A : notes 4–5 = (36+30)/100 = **66 %** ; notes au plus égales à 2 = (6+10)/100 = **16 %**. Magasin B : notes 4–5 = (34+20)/100 = **54 %** ; notes au plus égales à 2 = (4+12)/100 = **16 %**.

4. Trente est bien supérieur de 50 % à vingt, mais ce calcul isole une seule modalité et ne signifie pas que le magasin est « 50 % meilleur ». Pour les notes 4–5, l'écart est de 12 points ; la méthode d'échantillonnage et l'incertitude sont inconnues, et aucune causalité n'est établie.

5. Conclusion modèle. « Dans les échantillons interrogés, le magasin A présente davantage de notes favorables (66 %) que le magasin B (54 %), tandis que les deux magasins comptent 16 % de notes 1 ou 2. Cette différence reste descriptive et ne prouve pas à elle seule que le magasin A offre un meilleur service. Avant toute généralisation, il faut connaître la sélection des clients, les taux de réponse et la comparabilité des périodes. »

3. Approfondissement facultatif

Aller plus loin dans l'interprétation et les applications professionnelles.

Approfondissement 15 min

Complément 2 — Protocole de qualité et de communication

Un export CRM contient des clients dupliqués, des âges manquants codés 999, des dates incohérentes et des revenus saisis en euros ou en milliers d’euros. Proposez un protocole reproductible en six étapes avant de produire un tableau de bord.

Séparez validation, nettoyage, documentation et communication.

Complément 2 — Protocole de qualité et de communication

Corrigé détaillé

1. Conserver un fichier brut immuable et les identifiants.
2. Établir un dictionnaire des variables et unités.
3. Détecter les doublons et définir une règle de conservation.
4. Recoder 999 en valeur manquante et analyser la non-réponse.
5. Contrôler dates, plages et cohérence logique.
6. Uniformiser les unités monétaires, documenter les transformations et publier les contrôles.

On ne remplace jamais silencieusement les valeurs manquantes et on ne supprime pas automatiquement les observations inhabituelles.