Fiche 4

Distributions bivariées et régression

Corrigés détaillés

Badr ABOUFARASSE, PhD

1. Applications fondamentales

Maîtriser les définitions et les calculs essentiels du cours.

Application du cours 15 min

Exercice 3 – Droite de Mayer

Pour les points $(1,7),(2,10),(3,10),(4,14),(5,14)$: former deux sous-nuages, calculer leurs points moyens A et B, puis déterminer la droite de Mayer.

Exercice 3 – Corrigé

Premier sous-nuage : $(1,7),(2,10),(3,10)$:

$$A=\left(\frac{1+2+3}{3},\frac{7+10+10}{3}\right)=(2,9).$$

Deuxième sous-nuage : $(4,14),(5,14)$:

$$B=\left(\frac{4+5}{2},\frac{14+14}{2}\right)=(4.5,14).$$

$$a=\frac{14-9}{4.5-2}=2,\qquad b=9-2(2)=5.$$

Donc :

$$\boxed{y=2x+5}.$$

Construction vérifiable des deux points moyens

Groupe	x	y	Moyenne x	Moyenne y
A	1, 2, 3	7, 10, 10	6/3=2	27/3=9

Groupe	x	y	Moyenne x	Moyenne y
B	4, 5	14, 14	9/2=4.5	28/2=14

$$a = (14-9)/(4.5-2) = 2, \quad b = 9 - 2\times 2 = 5.$$

Contrôles : 2×2+5=9 et 2×4,5+5=14. La droite de Mayer n’est pas nécessairement la droite des moindres carrés.

2. Préparation aux évaluations

Résoudre des exercices de contrôle continu et de partiel en autonomie.

Préparation CC / partiel 35 min

Exercice 1 – Régression linéaire complète

On observe :

$$(1,3),\ (2,5),\ (3,5),\ (4,8),\ (5,9).$$

1. Tracer le nuage de points et décrire direction, forme et intensité apparente.
2. Calculer $\bar{x}$, $\bar{y}$, $V(x)$, $V(y)$, $\mathrm{Cov}(x,y)$ et le coefficient de corrélation r.
3. Estimer la droite des moindres carrés $\hat{y} = ax + b$.
4. Calculer les valeurs ajustées et les résidus $e_i = y_i - \hat{y}_i$.
5. Calculer SSE, SST et R^2 ; interpréter R^2.

Exercice 1 – Corrigé détaillé

$$\bar{x} = 3, \qquad \bar{y} = 6.$$

$$V(x) = \frac{(1-3)^2 + (2-3)^2 + (3-3)^2 + (4-3)^2 + (5-3)^2}{5} = 2.$$

$$V(y) = \frac{(3-6)^2 + (5-6)^2 + (5-6)^2 + (8-6)^2 + (9-6)^2}{5} = 4.8.$$

$$\mathrm{Cov}(x,y) = \frac{1}{5}\sum (x_i - \bar{x})(y_i - \bar{y}) = 3.$$

$$r = \frac{3}{\sqrt{2 \times 4.8}} \approx 0.96825.$$

Pente et constante :

$$a = \frac{\mathrm{Cov}(x,y)}{V(x)} = \frac{3}{2} = 1.5,$$

$$b = \bar{y} - a\bar{x} = 6 - 1.5(3) = 1.5.$$

Donc :

$$\boxed{\hat{y} = 1.5x + 1.5}.$$

x_i	1	2	3	4	5
y_i	3	5	5	8	9
$\hat{y}_i$	3	4.5	6	7.5	9
e_i	0	0.5	-1	0.5	0

$$SSE = 0^2 + 0.5^2 + (-1)^2 + 0.5^2 + 0^2 = 1.5.$$

$$SST = \sum (y_i - \bar{y})^2 = 24.$$

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.5}{24} = 0.9375.$$

Environ 93.75% de la variation observée de Y autour de sa moyenne est associée à l'ajustement linéaire.

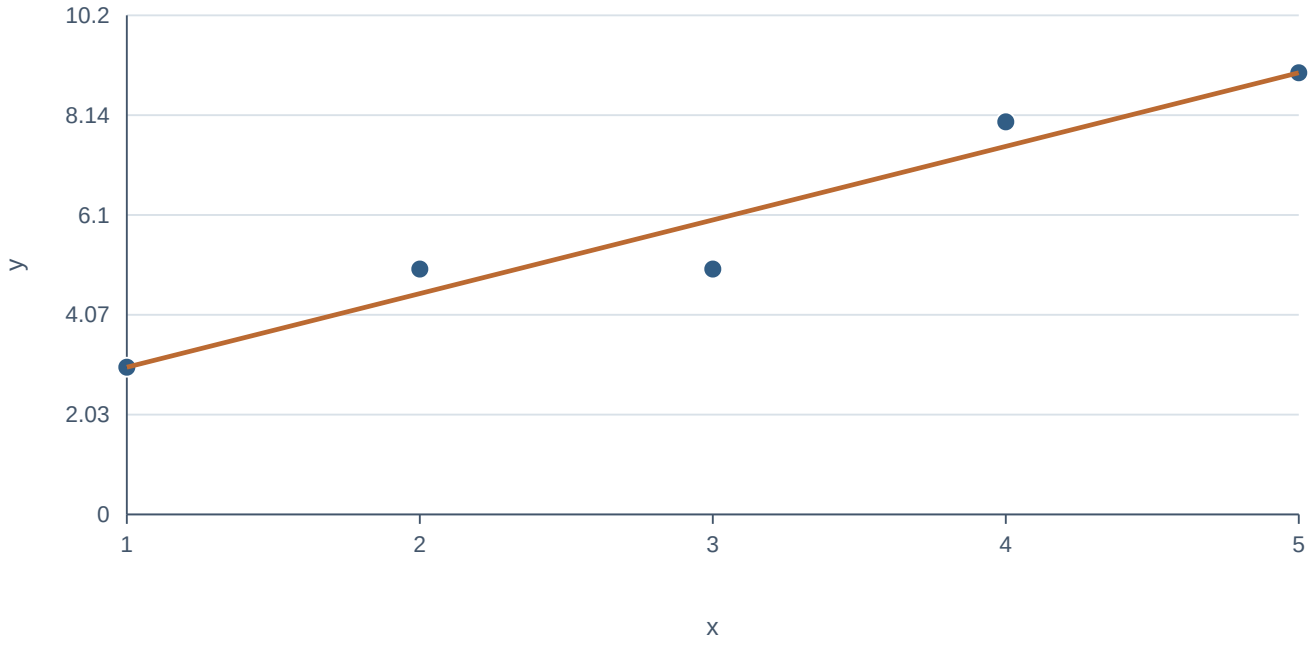
Tableau complet de calcul, avec résidus et carrés des résidus :

x_i	y_i	x_i^2	y_i^2	$x_i y_i$	$\hat{y}_i$	e_i	e_i^2	
1	3	1	9	3	3	0	0	
2	5	4	25	10	4.5	0.5	0.25	
3	5	9	25	15	6	-1	1	
4	8	16	64	32	7.5	0.5	0.25	
5	9	25	81	45	9	0	0	
Σ	15	30	55	204	105	30	0	1.5

$$\bar{x} = 15/5 = 3, \quad \bar{y} = 30/5 = 6, \quad V(x) = 55/5 - 3^2 = 2, \quad V(y) = 204/5 - 6^2 = 4.8.$$

$$\mathrm{Cov}(x, y) = 105/5 - 3(6) = 3, \quad a = 3/2 = 1.5, \quad b = 6 - 1.5(3) = 1.5.$$

$$SSE = 0 + .25 + 1 + .25 + 0 = 1.5, \quad SST = 24, \quad R^2 = 1 - 1.5/24 = .9375.$$



Nuage de points / Scatter and OLS line

Préparation CC / partiel 15 min

Exercice 4 – Prévision en deux étapes

Mois	1	2	3	4	5	6	7	8
Publicité X	12	15	14	18	20	22	25	27
Ventes Y	48	52	50	59	63	68	73	78

On donne les deux ajustements :

$$\widehat{Y} = 2.064X + 21.899, \qquad \widehat{X}_t = 2.155t + 9.429.$$

Prévoir la dépense publicitaire puis les ventes au mois 10. Identifier le caractère d'extrapolation de la première étape.

Exercice 4 – Corrigé

Au mois 10 :

$$\widehat{X}_{10} = 2.155(10) + 9.429 = 30.979 \approx 30.98.$$

Cette valeur dépasse le maximum publicitaire observé, 27 : la première étape extrapole la tendance au-delà du mois 8.

La deuxième étape donne :

$$\widehat{Y}_{10} = 2.064(30.98) + 21.899 \approx 85.84.$$

La prévision finale des ventes est donc d'environ 85.84 milliers d'euros.

Calcul complet des deux étapes

t	1	2	3	4	5	6	7	8
X	12	15	14	18	20	22	25	27
Y	48	52	50	59	63	68	73	78

$$\widehat{X}_{10} = 2.155(10) + 9.429 = 21.55 + 9.429 = 30.979.$$

$$\widehat{Y}_{10} = 2.064(30.979) + 21.899 = 63.940656 + 21.899 = 85.839656.$$

Le mois 10 est hors de l'intervalle observé 1–8 et la publicité prévue 30,979 est supérieure au maximum observé 27 : double extrapolation, à interpréter avec prudence.

Préparation CC / partiel 45 min

Exercice 5 — Deux régressions successives — type partiel

Sur six périodes, on observe le rang t, la publicité x et les ventes y.

t	1	2	3	4	5	6
x	4	5	7	8	10	11
y	10	12	15	18	22	24

1. Construire le tableau complet t, x, y, t^2, x^2, y^2, tx, xy et les sommes.
2. Calculer les moyennes, variances, covariance, r et la droite de x en fonction de t.
3. Faire de même pour y en fonction de x.
4. Prévoir x puis y pour t=8 ; qualifier les extrapolations.

Exercice 5 — Corrigé intégral

t	x	y	t^2	x^2	y^2	t×x	x×y
1	4	10	1	16	100	4	40
2	5	12	4	25	144	10	60
3	7	15	9	49	225	21	105
4	8	18	16	64	324	32	144
5	10	22	25	100	484	50	220
6	11	24	36	121	576	66	264
Σt=21	45	101	91	375	1853	183	833

Régression de x sur t.

$$\bar{t} = 21/6 = 3.5,\ \bar{x} = 45/6 = 7.5,\ V(t) = 91/6 - 3.5^2 = 2.916667,\ V(x) = 375/6 - 7.5^2 = 6.25.$$

$$\mathrm{Cov}(t,x) = 183/6 - 3.5(7.5) = 4.25, \quad r_{tx} = \frac{4.25}{\sqrt{2.916667 \times 6.25}} = .995418.$$

$$a_1 = 4.25/2.916667 = 1.457143, \quad b_1 = 7.5 - a_1(3.5) = 2.4, \quad \widehat{x}_t = 1.457143t + 2.4.$$

Régression de y sur x.

$$\bar{y} = 101/6 = 16.833333, \quad V(y) = 1853/6 - (101/6)^2 = 25.472222, \quad \mathrm{Cov}(x,y) = 833/6 - (45/6)(101/6) = 12.583333.$$

$$r_{xy} = \frac{12.583333}{\sqrt{6.25 \times 25.472222}} = .997292, \quad a_2 = 12.583333/6.25 = 2.013333, \quad b_2 = 16.833333 - a_2(7.5) = 1.733333.$$

$$\hat{y} = 2.013333x + 1.733333, \quad \widehat{x}_8 = 14.057143, \quad \hat{y}_8 = 2.013333(14.057143) + 1.733333 = 30.035048.$$

t=8 dépasse la plage observée 1–6. Les deux étapes extrapolent ; aucune causalité n'est établie.

3. Approfondissement facultatif

Aller plus loin dans l’interprétation et les applications professionnelles.

Approfondissement 20 min

Exercice 2 – Interpolation, extrapolation, causalité et influence

À partir du modèle de l’exercice 1 :

1. prévoir Y pour $X = 3.5$ et qualifier la prévision ;
2. prévoir Y pour $X = 10$ et expliquer pourquoi cette prévision est risquée ;

3. ajouter le point $(10, 30)$ et recalculer la pente et l'ordonnée à l'origine ; commenter l'influence de ce point ;
4. expliquer pourquoi une forte corrélation ne prouve pas une relation causale.

Exercice 2 – Corrigé détaillé

Pour $X = 3.5$:

$$\hat{y} = 1.5(3.5) + 1.5 = 6.75.$$

Comme $3.5 \in [1, 5]$, il s'agit d'une interpolation.

Pour $X = 10$:

$$\hat{y} = 1.5(10) + 1.5 = 16.5.$$

Mais 10 est très au-delà du maximum observé 5 : c'est une extrapolation risquée.

Après ajout de $(10, 30)$, la nouvelle droite est approximativement :

$$\hat{y} = 3.04918x - 2.70492.$$

La pente passe de 1.5 à environ 3.05 : le point est très influent sur la droite ajustée. Une forte corrélation reste une mesure d'association ; elle ne suffit pas à établir une causalité, car des variables omises, une causalité inverse ou des mécanismes communs peuvent produire l'association.

Après ajout de (10,30), N=6, Σx=25, Σy=60, Σx²=155, Σy²=1104, Σxy=405.

$$V(x) = 155/6 - (25/6)^2 = 8.472222, \quad \mathrm{Cov}(x, y) = 405/6 - (25/6)(60/6) = 25.833333.$$

$$a = 25.833333/8.472222 = 3.049180, \quad b = 10 - 3.049180(25/6) = -2.704918.$$

La pente passe de 1,50 à 3,05 : le point supplémentaire est influent.

Approfondissement 20 min

Complément 1 — Diagnostic de régression et décision responsable

Un modèle reliant fréquentation et température donne r = 0,78 et R² = 0,61. Le graphique des résidus est en U, un week-end d'été présente un résidu très élevé et le responsable veut prévoir une température supérieure de 12 °C au maximum observé.

1. Interprétez r et R².
2. Diagnostiquez les résidus.
3. Discutez le week-end atypique et la prévision.
4. Recommandez les étapes suivantes.

Distinguez intensité, forme fonctionnelle, observation inhabituelle, extrapolation et causalité.

Complément 1 — Diagnostic de régression et décision responsable

Corrigé détaillé

Corrélation. r = 0,78 décrit une association linéaire positive assez forte dans l’échantillon ; elle ne prouve pas la causalité.

R^2. Environ 61 % de la variation observée de la fréquentation autour de sa moyenne est expliquée par la droite. Cela ne signifie pas que la température « cause 61 % » de la fréquentation.

Résidus. Une forme en U révèle une courbure non prise en compte : la spécification linéaire est inadéquate.

Week-end inhabituel. Vérifier la donnée et rechercher festival, promotion ou fermeture. Comparer les estimations avec et sans ce point, sans le supprimer automatiquement.

Extrapolation. Prévoir 12 °C au-delà du maximum est très risqué, d’autant que la non-linéarité est visible.

Suite. Tester un terme quadratique ou une courbe flexible, valider hors échantillon, intégrer calendrier et promotions, mesurer l’influence et présenter l’incertitude.